

Grupo 4

Augusto Peroni Baldino
Enzo Silveira
Felipe Freitas Silva
Luiza Heller Kroeff Plá
Maria Eduarda Wendel Maia
Paola Anacleto Lopes

1) Encontre 3 datasets diferentes (ex: kaggle, huggin face, ...) que estejam cada um em um dos seguintes formatos: estruturado, não estruturado e semiestruturado. Forneça uma descrição de cada dataset (nome, criador, data da criação, características e volume) bem como o link para a página ou download do dataset.

1. Estruturado

- a. Nome: Monthly Stack Overflow Questions
- b. Link: <https://www.kaggle.com/datasets/computingvictor/monthly-trends-in-stack-overflow-questions>
- c. Criador: Víctor Vilorio
- d. Data de Criação: 08/31/2008
- e. Características:

Views: 357 nos últimos 30 dias.

Downloads: 45 nos últimos 30 dias.

Expected Update Frequency: quarterly.

Geospatial Coverage: Worldwide.

- f. Volume: 19.32kB

2. Não estruturado

- a. Nome: OASIS Alzheimer's Detection
- b. Criador: Ninad Aithal
- c. Data de Criação: Junho de 2023
- d. Características: Este dataset contém imagens de ressonância magnética cerebral para a detecção de Alzheimer, ideal para tarefas de visão computacional e aprendizado profundo.
- e. Volume: 1.3 GB
- f. Link: <https://www.kaggle.com/datasets/ninadaithal/imagesoasis>

3. Semi estruturado

- a. Nome: Mango Products
- b. Link: <https://www.kaggle.com/datasets/maparla/mango-products>
- c. Criador: Mario Parreño Lara
- d. Data de Criação: Last updated 10 days ago.
- e. Características:
 - i. Views: 2105
 - ii. Downloads: 292
- f. Volume: 2.5kB

2) Para o dataset com dados estruturados, identifique, quando possível, aos menos 3 dados quantitativos (contínuo e discreto) e 3 qualitativos (nominal e ordinal, simbólico e categórico).

Quantitativos:

1. Contínuo: Peso
2. Contínuo: Temperatura
3. Discreto: Idade

Qualitativos:

1. Nominal: Sexo
2. Ordinal: Classe Social
3. Simbólico: -
4. Categórico: -

3) O que significa ETL? E qual sua importância para Machine Learning?

O ETL é o processo de extração, transformação e carga de dados para construir o dataset, em outras palavras é um processo para integrar e consolidar dados de diferentes fontes em um único local, e cada letra da sigla representa:

- E -> Extract (Extração) de diferentes fontes de dados
- T -> Transform (Transformação) dos dados consiste na preparação para uso
- L -> Load (Carga) dos dados em um repositório

4) O que são outliers? E qual a consequência da presença deles para algoritmos de Machine Learning?

Outliers são dados que se diferenciam drasticamente de todos os outros dados e são considerados pontos fora da curva, influenciando a sua análise. Podem existir diferentes consequências provindas da sua presença em algoritmos de Machine Learning, como o

prejuízo do desempenho do modelo, levar a sobreajuste, causar sensibilidade a outliers ou até indicar eventos críticos que requerem atenção.

5) O que é estatística descritiva? Ela foi usada em um dos datasets que pesquisou? Qual a diferença entre média e mediana?

Também chamada de análise exploratória de dados, está diretamente ligada à organização e descrição dos dados. Reúne uma quantidade de ferramentas que podem auxiliar no entendimento de valores observados, podendo ser categorizadas em medidas de localização, dispersão e distribuições de frequência;

Foi usada;

A mediana é a medida que divide metade dos dados ordenados, à sua esquerda os valores menores, e à sua direita valores maiores, já a média é a soma de todos os valores dividida pela quantidade total

6) Qual a diferença entre dados univalorados e multivalorados? Dê exemplos.

Dados univalorados são dados que possuem apenas um valor por entidade, como por exemplo CPF, que cada pessoa tem o seu, contudo, os dados multivalorados podem possuir múltiplos valores, como por exemplo telefone, em que a pessoa pode ter mais de um.

7) No que a covariância e a correlação são úteis?

A covariância e a correlação são úteis para o estudo dos dados obtidos, para que possa ser feita a comparação entre duas variáveis, utilizamos a covariância e para que possa ser feita a cardinalidade entre duas variáveis.

8) Qual a utilidade das medidas de dispersão? E quais você encontrou no material?

As medidas de dispersão estão associadas a parâmetros da escala. Encontramos medidas como amplitude, variância, desvio padrão, coeficiente de variação, etc.