

Enunciado

1. **Caso você não tenha conseguido concluir a atividade da aula anterior, use esta aula para concluir a atividade 3.**
2. **Como base nos pdfs de aula e materiais complementares (programas), entenda o propósito e a lógica do algoritmo de agrupamento Hierárquico (pdf sobre agrupamento - parte 2).**
3. **A seguir , responda:**
 - **Qual a diferença entre agrupamento particional e hierárquico?**
 - **Por que é preferível usar métodos "aglomerativos" e não usar "por divisão" no caso de agrupamento hierárquico? Justifique.**
 - **Os algoritmos hierárquicos recebem seus nomes baseados no critério usado para medir a distancia entre os clusters. Que critérios são esses? Explique-os analisando os diferentes algoritmos hierárquicos presente no material de aula. Comente as diferenças entre esses algoritmos.**

Respostas

1. Qual a diferença entre agrupamento particional e hierárquico?

A principal diferença entre esses dois tipos de agrupamento, se encontra na forma como cada um formata e organiza seus clusters.

No agrupamento particional é preciso especificar o número de clusters antes de executar o algoritmo, para que os algoritmos de agrupamento particional atribuam cada objeto um cluster inicial aleatório e depois vão ajustem a atribuição entre os clusters com o objetivo de otimizar algum critério.

Enquanto isso, no agrupamento hierárquico não é preciso especificar o número de clusters antes de rodar o algoritmo. Esse algoritmo vai primeiro criar uma estrutura de árvore, chama dendrograma, a partir dos dados, de forma que cada nó presente na árvore vai representar um cluster que contém um ou mais objetos.

Além dessa grande diferença, é interessante adicionar também que o agrupamento hierárquico possui dois tipos diferentes: bottom-up (aglomerativo) e top-down (por divisão), sendo o primeiro organizado de forma que cada objeto começa em seu cluster individual e os clusters subsequentes são criados a partir de combinações de clusters mais similares, enquanto que no top-down, todos os objetos começam em um único cluster e todos os posteriores vão ser formados a partir da divisão do cluster existente em clusters menores.

2. **Por que é preferível usar métodos "aglomerativos" e não usar "por divisão" no caso de agrupamento hierárquico? Justifique.**

Existem algumas razões para essa preferência, entre elas podemos citar:

- **Menor Sensitividade a Outliers:** os métodos aglomerativos são menos sensíveis a outliers, uma vez que cada objeto começa em seu próprio cluster e esses são gradualmente combinados com base na similaridade, o que reduz o impacto que os outliers podem causar em comparação com a divisão, onde os pontos começam em um único cluster e são divididos progressivamente.
- **Não é Necessário Especificar o Número de Clusters:** isso proporciona mais flexibilidade e liberdade quando formos explorar a estrutura dos dados em diferentes granularidades de agrupamento.
- **Menor Complexidade Computacional:** isso ocorre porque o número de operações necessárias para mesclar os clusters é proporcional ao número total de pontos de dados, e nos métodos por divisão, o número de operações pode crescer exponencialmente à medida que mais divisões são feitas.

3. **Os algoritmos hierárquicos recebem seus nomes baseados no critério usado para medir a distancia entre os clusters. Que critérios são esses? Explique-os analisando os diferentes algoritmos hierárquicos presente no material de aula. Comente as diferenças entre esses algoritmos.**

Os critérios encontrados foram:

Ward: que minimiza a variância dos clusters que estão sendo unidos. Esse critério é eficaz em minimizar a variação entre os clusters, de forma que tende a formar clusters compactos com alta coesão.

Average: esse critério faz o calculo da distância média entre os pares de pontos que pertencem a diferentes clusters. Ele cria clusters com formas mais equilibradas e que são menos sentíveis a outliers do que outros critérios. É importante notar que ele é mais custoso computacionalmente, já que precisa do cálculo das distâncias médias entre todos os pares de pontos.

Complete: esse critério vai considerar a maior distância entre todos os pontos de cada cluster ao computar a distância entre dois clusters. Basicamente ele vai avaliar a distância máxima entre todos os pares de pontos que pertencem a diferentes clusters.

Single: que considera a menor distância entre os pontos de cada cluster, ou ainda, ele avalia a distância mínima entre os pares de pontos pertencentes a diferentes clusters. Esse critério produz clusters mais alongados e menos compactos.