



IA é uma área da ciência da computação que estuda a criação de agentes inteligentes.



Agentes são sistemas capazes de raciocinar, aprender e atuar de forma autônoma.




O estudo moderno de IA começou durante os anos 50, com o trabalho fundamental de Alan Turing.



Subáreas da IA

ML é o processo de desenvolver modelos e algoritmos que permitam que sistemas computacionais realizem tarefas sem instruções específicas.



Machine Learning

Estuda como simular o raciocínio lógico, usando modelos lógicos e provas para raciocinar sobre os possíveis comportamentos de um sistema ou programa, mesmo estados que ele pode nunca alcançar.



Raciocínio
Automatizado

Agentes físicos e/ou virtuais que executam tarefas de forma autônoma para atender a algum objetivo.



Robótica

XAI
Processos e métodos que ajudam as pessoas a entenderem e confiarem nos resultados gerados por algoritmos de ML



IA Explicável

PLN
Tem como objetivo dar aos computadores a capacidade de entender e gerar a linguagem humana.



Processamento
de Linguagem
Natural

Estuda como colocar o conhecimento em uma forma que o computador consiga usar em um processo de raciocínio.



Representação
de Conhecimento

Computadores e sistemas conseguem obter informações significativas de diferentes entradas visuais, e com elas tomar decisões ou fazer recomendações.




Visão
Computacional

Problemas



Heurística – Busca Informada

Uma forma de estimar o que está mais próximo do resultado final.



Machine Learning

Aprendizado de Máquina.

Sub-área da inteligência artificial.

Usa aprendizado indutivo.

Sub-áreas de ML:

Aprendizado Profundo – Deep Learning.

Aprendizado Supervisionado.

Aprendizado Não-Supervisionado.

Aprendizado por Reforço.

Aprendizado Auto-Supervisionado.

Aprendizado Semissupervisionado.



“Permite que um sistema aprenda e melhore de forma autônoma usando redes neurais e aprendizado profundo, sem ser programado explicitamente, alimentando-o com grandes quantidades de dados.”

Paradigmas de Aprendizado



Machine Learning



SUPERVISED
TASK DRIVEN
(PREDICT NEXT VALUE)

Aprendizado Supervisionado

Dados rotulados.



Algoritmos recebem pares de valores: dados de entrada (x) e valores de saída (rótulos) correspondentes (y).

O modelo recebe um conjunto de entradas com suas respectivas saídas e tenta encontrar uma função (hipótese) que estabeleça uma relação aproximada entre elas.

Calibragem do nível de assertividade e precisão.

Ajuste na complexidade do modelo, para evitar a ocorrência de underfitting_sub-ajuste_ e overfitting_superajuste.

Associados às tarefas de regressão e classificação



Tarefa Preditiva

Encontra um modelo a partir dos dados de treino que possa ser usado para prever um rótulo.



Classificação

Rótulos discretos.

Automaticamente atribui rótulos a dados.

Binária – apenas 2 classes.

Multiclasse – 2+ classes.

Single Label.

Multi-label.



Regressão

Rótulos contínuos.

Automaticamente predizer novos valores de y.

Machine Learning

Classificação

Se os dados fossem estruturados, que atributos/características seriam mais importantes e significativos para a classificação?

Saída (y):
rótulo/classe/anotação

Gato



<https://www.pexels.com/>

Cachorro



Galinha



Dataset Anotado

Algoritmo k-NN

K – Nearest Neighbour: algoritmo dos k vizinhos mais próximos.

Considera os objetos mais próximos com características semelhantes para prever a classe de um novo dado.

Etapa de Treinamento – não gera modelo, apenas memorização dos dados rotulados.

Etapa de Generalização

Machine Learning



UNSUPERVISED
DATA DRIVEN
(IDENTIFY CLUSTERS)


Aprendizado Não Supervisionado

Inferências a partir de um conjunto de dados que não foi rotulado, classificado ou categorizado antes.

Usa regularidades e propriedades estatísticas dos dados.

Usos:

- Descoberta de padrões nos dados;
- Tarefas de agrupamento;
- Redução de dimensionalidade;
- Encontrar número inferior de variáveis que melhor representam as características dos conjuntos de dados.
- Identificação de anomalias nos dados.




Fluxo de execução do aprendizado não supervisionado.

Tarefas Descritivas

Explora ou descreve um conjunto de dados.

- Agrupamento – divisão em grupos baseada em alguma regularidade.
- Sumarização – descrição simples e compacta.
- Associação – relações frequentes entre dados.



Agrupamento




Figure 4.2: Exemplo de dois agrupamentos em um plano com duas dimensões (X,Y). Observam-se 3 grupos em a) e 8 grupos em b). Adaptado de Esling and Agon (2012)

Categorização dos dados.

Utiliza alguma medida de similaridade.

Pode ser usado como uma etapa antes de alguma tarefa como a sumarização.

Grupos são formados por dados (objetos) que compartilham características.

Alta similaridade intra-grupo.

Baixa similaridade entre grupos.

Sistemas de recomendação são uma das principais aplicações que utilizam essa abordagem.

Etapas de Agrupamento


Preparação
Pré-processamento de dados utilizando técnicas como:
Normalização; Conversão de tipos; Redução de Dimensionalidade.


Agrupamento
Uso de um ou mais algoritmos de agrupamento para gerar os grupos.


Proximidade
Essencial para garantir análises de dados precisas e relevantes.
Definição de medidas de proximidade apropriadas.


Validação
Checar se os grupos são significativos.


Interpretação
Análise do grupo em relação aos outros para rotulá-los, indicando a natureza do grupo.

Agrupamento Particional


Cada objeto está em exatamente um único grupo.

O número de grupos é definido pelo usuário.


Exclusive cluster separation – hard cluster.

Medidas de distâncias usadas para determinar o grau de similaridade de cada grupo.

Centroide: média ou qualquer outra medida estatística de cada grupo. Os objetos são atribuídos ao grupo com centroide mais próximo. Geralmente aleatórios.



Exemplo de um agrupamento baseado em partição. As linhas pretas demarcam as partições e as formas geométricas preenchidas os centróides.



Definindo K

Método do Cotovelo

Testa a variância dos dados em relação aos centróides dos clusters



Algoritmo k-Means

K = número de grupos em que o conjunto de dados foi dividido.

Diminuir a variação intra-grupos → criar grupos em que os objetos sejam semelhantes entre si.

Em cada iteração os centróides de cada grupo são atualizados para refinar a qualidade dos grupos.

Complexidade $O(n.k.i.d)$ – num de objetos, de grupos, de iterações e de atributos.



Centroide

Medida estatística de cada grupo, geralmente a média de todos os objetos.

Medida da distância: Manhattam ou Euclidiana


Medida Manhattam

$$d(x_i, x_j) = \sum_{l=1}^d |x_i^l - x_j^l|$$

Os objetos são atribuídos ao grupo com centroide mais próximo.

Geralmente aleatórios.

Etapas



Agrupamento Hierárquico


Vários grupos aninhados na forma de uma árvore hierárquica.

O usuário não precisa especificar o número de grupos.

Algoritmo busca por correlações entre os objetos do conjunto de dados pra criar os grupos.

Algoritmos AGNES são mais usados.

Operação-chave: distância entre os dois clusteres.




AGNES

Agrupamento hierárquico aglomerativo.

Agglomerative Nesting.

No início cada objeto tem seu próprio grupo, e a cada iteração, os dois grupos mais parecidos são unidos, formando um novo grupo. Isso se repete até só existir um único grupo.



DIANA

Agrupamento hierárquico divisivo.

Divise Analysis.

Primeiro todos os objetos pertencem a um único grupo e depois ele é dividido até obter um grupo para cada objeto ou até que um critério de parada seja atingido.

Para definir os grupos usa uma matriz de similaridade ou distância.